

GLOBAL SOLUTION – SISTEMAS OPERACIONAIS

Análise da Influência dos Padrões Numéricos int8 e float64 no Treinamento de uma Rede Neural MLP Aplicada a Dados de Pouso Aeronáutico

Integrantes:

- Eduardo Mazelli - RM:553236
- Lucas Masaki - RM:553084
- Pedro Henrique Lima - RM:552746
- Carolina Cavalli - RM:552925
- Joseh Gabriel Trimboli Agra - RM: 553094

Repositório do GitHub:

<https://github.com/Zoviskgabriel/GS-Sistemas-Operacionais>

Questão de Pesquisa:

Como os padrões numéricos int8 e float64 influenciam a precisão, o desempenho e o tempo de processamento de uma rede neural MLP aplicada à inferência de dados de pouso de aeronaves em sistemas embarcados com Kernel de 64 bits?

Objetivo Geral:

Avaliar a influência dos padrões numéricos int8 e float64 sobre a qualidade das inferências e o desempenho computacional de uma rede neural artificial aplicada a dados aeronáuticos.

Objetivos Específicos:

- Construir um conjunto de dados representando condições de pouso;
- Preparar os dados para treinamento;
- Implementar uma rede neural MLP;
- Comparar os formatos float64 e int8;
- Avaliar métricas de desempenho;
- Analisar a influência da preempção do sistema operacional.

Equações Cinemáticas Utilizadas

Para representar as condições de pouso, foram consideradas variáveis relacionadas à dinâmica da aeronave.

Equação da velocidade:

$$v = v_0 + at$$

Onde:

- v = velocidade final;
- v_0 = velocidade inicial;
- a = aceleração;
- t = tempo.

Equação da posição:

$$s = s_0 + v_0t + \frac{1}{2}at^2$$

Onde:

- s = posição final;
- s_0 = posição inicial;
- v_0 = velocidade inicial;
- a = aceleração;
- t = tempo.

Essas fórmulas foram utilizadas como base para a geração dos dados relacionados ao pouso da aeronave.

Exploração e Preparação dos Dados:

Foi desenvolvido um dataset sintético contendo aproximadamente 6 milhões de registros.

As variáveis utilizadas foram:

- Velocidade de aproximação;
- Altitude;
- Taxa de descida;
- Vento lateral;
- Peso da aeronave.

A variável alvo foi a distância estimada para pouso.

Após a geração dos dados, foi realizada a etapa de normalização utilizando StandardScaler para reduzir diferenças de escala entre os atributos.

Em seguida, os dados foram divididos em:

- 80% para treinamento;
- 20% para testes.

Arquitetura da Rede Neural:

Foi utilizada uma rede neural do tipo Multilayer Perceptron (MLP).

Configuração adotada:

- 5 variáveis de entrada;
- 1 camada oculta;
- 20 neurônios na camada oculta;
- Função de ativação sigmoideal (logistic);
- 1 neurônio de saída.

O treinamento foi realizado utilizando a biblioteca Scikit-Learn.

Foram executados dois experimentos independentes:

1. Utilizando float64;
2. Utilizando int8.

Resultados Obtidos:

As métricas utilizadas para avaliação foram:

- Tempo de processamento;
- Mean Squared Error (MSE);
- Mean Absolute Error (MAE).

Métrica

Float64

Int8


Tempo (min)	1,4237	1,7628
MSE	3,1707	304327,4105
MAE	1,2637	457,3551

Os resultados demonstram que o modelo treinado com float64 apresentou desempenho significativamente superior ao modelo treinado com int8.

O baixo valor de MSE e MAE obtido pelo float64 indica elevada precisão durante as previsões realizadas pela rede neural.


Já o modelo int8 apresentou perda significativa de precisão devido à limitação de representação numérica desse formato.

Comparação do Tempo de Processamento




O gráfico demonstra o tempo total necessário para o treinamento da rede neural em cada formato numérico. Observa-se que o treinamento utilizando float64 apresentou menor tempo de execução em comparação ao experimento realizado com int8.

Comparação do Erro Quadrático Médio (MSE):




O gráfico apresenta os valores de MSE obtidos nos experimentos. O modelo treinado com float64 apresentou erro significativamente menor, indicando maior precisão nas previsões realizadas pela rede neural.

Comparação do Erro Absoluto Médio (MAE):



Os resultados mostram que o formato float64 obteve menor erro absoluto médio, demonstrando melhor capacidade de aproximação dos valores reais quando comparado ao formato int8.

Evolução da Função de Perda (Loss):



A curva de loss apresenta a evolução do processo de aprendizagem da rede neural ao longo das épocas de treinamento. A redução progressiva da função de perda demonstra a convergência do modelo durante o treinamento.

Influência da Preempção do Sistema Operacional:

A preempção é um mecanismo utilizado pelos sistemas operacionais para interromper temporariamente a execução de um processo e permitir a execução de outro processo considerado prioritário.

Durante o treinamento da rede neural, o escalonador do sistema operacional pode realizar trocas de contexto entre processos.

Essas interrupções podem aumentar o tempo total de processamento, porém não alteram os cálculos matemáticos realizados pela rede neural.

Em sistemas embarcados aeronáuticos, a previsibilidade temporal é um fator importante para garantir confiabilidade operacional.

Conclusão:

Os experimentos realizados demonstraram que o padrão numérico utilizado influencia diretamente a qualidade das inferências produzidas pela rede neural.

O modelo treinado utilizando float64 apresentou os melhores resultados em todas as métricas avaliadas, alcançando baixo erro e melhor desempenho geral.

Embora o padrão int8 apresente potencial redução de consumo de memória, sua limitação de precisão resultou em degradação significativa da qualidade das previsões.

Dessa forma, conclui-se que o formato float64 é a alternativa mais adequada para aplicações aeronáuticas que exigem elevada precisão e confiabilidade.